



UNIVERSITÀ DEGLI STUDI
DI SALERNO

U.S. CHRONIC DISEASE DATA ANALYSIS

Studio statistico sui dati delle malattie croniche negli Stati Uniti, basato su indicatori di salute pubblica forniti dal CDC (Centers for Disease Control and Prevention).

Studenti

Mattia Maucioni

Antonio Landi

Corso: Statistica e Analisi dei Dati 2024/2025

Professori: Stefano Cirillo, Luigi Di Biasi

Indice

1	Introduzione	3
2	Analisi Esplorativa	3
2.1	Struttura del Dataset	3
2.2	Conteggio delle occorrenze e identificazione dei valori nulli	4
2.3	Conteggio delle occorrenze per anno di acquisizione	4
2.4	Tipologie di dati: DataValueType e DataValueUnit	5
2.5	Stratificazione dei Dati per Categoria Demografica	6
2.6	Distribuzioni divise per DataValueType ⁺	7
2.7	Verifica delle distribuzioni ⁺	7
2.8	Verifica delle ipotesi ⁺	8
2.9	Moda sui Dati Qualitativi	8
3	Obiettivi del Progetto	10
4	Research Question: 1	10
4.1	Prompt	10
4.2	Primo approccio (GPT-4)	11
4.3	Secondo approccio (GPT-5)	12
5	Research Question: 2	14
5.1	Matrici di Correlazione	14
5.2	Limitazioni e direzioni di miglioramento	15
6	Research Question: 3	17
6.1	Analisi di clustering (K-Means)	17
6.2	Classificazione supervisionata (Random Forest)	18
6.3	Valutazione della bontà dei cluster ⁺	19
6.4	Discussione dei risultati	20

1 Introduzione

Il dataset U.S. Chronic Disease Data, fornito dal Centers for Disease Control and Prevention (CDC), raccoglie un insieme di 124 indicatori relativi alle malattie croniche, sviluppati attraverso un processo di consenso per garantire uniformità nella definizione, raccolta e reporting dei dati a livello statale, territoriale e metropolitano. Questi dati rappresentano una risorsa fondamentale per l'analisi della salute pubblica, offrendo una panoramica dettagliata sulla diffusione e l'impatto delle patologie croniche nella popolazione.

Le informazioni ricavate dall'analisi proposta in questo progetto sono raccolte tramite esecuzioni di codici in linguaggio R reperibili, come tutto il materiale, sull'apposita repository GitHub: [clicca qui](#).

2 Analisi Esplorativa

2.1 Struttura del Dataset

Il dataset in oggetto contiene informazioni raccolte dal **2001** al **2014** divise per topic. Riportiamo di seguito i topic univoci estratti dal dataset:

Topics	
Alcohol	Asthma
Arthritis	Cancer
Chronic Kidney Disease	COPD
Cardiovascular Disease	Diabetes
Tobacco	Disability
Immunization	Mental Health
Nutrition, PA, and Weight Status	Oral Health
Older Adults	Overarching Conditions
Reproductive Health	

Tabella 1: Lista dei topic presenti nel dataset.

Inoltre, all'interno del dataset, ciascun *topic* include un insieme di *question*, ognuna delle quali è identificata univocamente da un *questionID*. Ad esempio, per il topic *Alcohol*, la question "*Chronic liver disease mortality*" è associata al questionID `ALC6_0`.

L'analisi verrà condotta utilizzando i valori forniti dagli attributi `DataValue` e `DataValueAlt`, che rappresentano le misure quantitative e/o qualitative associate a ciascuna question.

Per completare la presentazione del dataset e comprenderne la struttura, è importante notare che ogni valore presente negli attributi `DataValue` o `DataValueAlt` può essere espresso secondo una diversa tipologia di dato, specificata nelle colonne `DataValueType` e `DataValueUnit`. La prima definisce il tipo di misura adottata, come ad esempio *Crude Prevalence* o *Age-Adjusted Prevalence*, mentre la seconda ne indica l'unità di misura, come *%*, *cases per 100,000* o *Number*. All'interno della stessa *question*, i dati possono essere rappresentati secondo differenti `DataValueType`, aggiungendo un ulteriore livello di granularità all'analisi. Inoltre, ogni record presente nel dataset fa riferimento a uno specifico anno di

acquisizione, a uno stato federale degli Stati Uniti, corredato di informazioni geospaziali, e a una *StratificationCategory*.

Quest'ultima permette di suddividere i dati secondo tre diverse categorie: *Race/Ethnicity*, che distingue la popolazione in gruppi etnici come *White*, *Black*, *Hispanic*, ecc.; *Overall*, che rappresenta il dato aggregato senza stratificazioni; e *Gender*, che distingue i valori in base al sesso (*Male*, *Female*).

2.2 Conteggio delle occorrenze e identificazione dei valori nulli

Dopo aver suddiviso l'intero dataset in diversi sottoinsiemi in base ai *topic*, la prima fase dell'analisi esplorativa ha riguardato il conteggio delle occorrenze per ogni *topic* e per ciascuna delle relative *question*. Questo passaggio ha permesso di identificare eventuali *topic* caratterizzati da un numero di record esiguo, potenzialmente non significativo per un'analisi approfondita, e, al contrario, *topic* con un volume di dati consistente su cui poter basare le fasi successive dell'analisi.

Successivamente, è stata effettuata un'analisi della presenza di valori nulli nei diversi *dataset* ottenuti, quantificando il numero di record incompleti per ciascuna *question*. Questo processo è stato fondamentale per comprendere la qualità e la completezza delle informazioni a disposizione, fornendo un quadro chiaro della disponibilità dei dati per le fasi successive del progetto.

Esempio sul *topic* "Diabete":




Figura 1

2.3 Conteggio delle occorrenze per anno di acquisizione

Un altro step dell'analisi esplorativa ha riguardato il conteggio delle occorrenze suddivise per *topic*, considerando anche l'anno di acquisizione del record. Questo passaggio ha permesso di identificare la distribuzione temporale dei dati, evidenziando eventuali anni con una quantità di occorrenze significativamente alta o bassa.

Per facilitare l'interpretazione dei risultati, i dati ottenuti sono stati rappresentati graficamente tramite digrammi a barre, consentendo di visualizzare in modo immediato gli anni più o meno rilevanti in termini di volume di dati. Questa analisi contribuisce a delineare un quadro più chiaro della struttura del dataset.




Figura 2

2.4 Tipologie di dati: *DataValueType* e *DataValueUnit*

Successivamente abbiamo effettuato l'estrapolazione delle informazioni relative all'attributo *DataValueType*, al fine di comprendere le tipologie di dati presenti all'interno del dataset.

A tal fine, sono stati identificati e raccolti tutti i valori univoci contenuti in *DataValueType*, associandoli ai corrispondenti valori presenti in *DataValueUnit*. Questo ha permesso di determinare, per ogni *topic*, la natura dei dati disponibili, distinguendo tra informazioni di tipo quantitativo e qualitativo e specificando, nel caso dei dati numerici, l'unità di misura adottata.

Questa analisi si è rivelata essenziale per comprendere la struttura del dataset e per guidare le fasi successive del processo analitico, fornendo una visione chiara della varietà e della granularità dei dati disponibili.

Di seguito un esempio per il *topic* "Alcohol":

"questionid"	"datavaluetype"	"datavalueunit"
"ALC10"	"Local control of the regulation of alcohol outlet density"	" "
"ALC11"	"Crude Prevalence"	"%"
"ALC12"	"Crude Prevalence"	"%"
"ALC21"	"Crude Prevalence"	"%"
"ALC22"	"Crude Prevalence"	"%"
"ALC22"	"Age-adjusted Prevalence"	"%"
"ALC23"	"Crude Prevalence"	"%"
"ALC30"	"Mean"	"Number"
"ALC30"	"Age-adjusted Mean"	"Number"
"ALC40"	"Mean"	"Number"
"ALC40"	"Age-adjusted Mean"	"Number"
"ALC51"	"Crude Prevalence"	"%"
"ALC51"	"Age-adjusted Prevalence"	"%"
"ALC52"	"Crude Prevalence"	"%"
"ALC60"	"Number"	" "
"ALC70"	"Per capita alcohol consumption"	"gallons"
"ALC801"	"US Dollars"	" "
"ALC802"	"US Dollars"	" "
"ALC803"	"US Dollars"	" "
"ALC90"	"Commercial host (dram shop) liability status for alcohol service"	" "

Tabella 2

2.5 Stratificazione dei Dati per Categoria Demografica

Un'altra informazione utile riguarda gli attributi *StratificationCategory* e *Stratification*. Il primo rappresenta le categorie di stratificazione dei dati, come *Razza/Etnia*, *Genere* e *Overall*, mentre il secondo specifica ulteriormente la categoria. Ad esempio, nel caso della stratificazione per razza o etnia, i valori possibili includono *Bianco*, *Nero*, *Ispanico*, *Non Ispanico*, ecc.; nel caso della stratificazione per genere, i valori includono *Uomo* e *Donna*.

Ogni dato raccolto all'interno del dataset è associato a una di queste categorie, il che permette di ottenere una visione più dettagliata dei fenomeni di salute pubblica. Questo consente di confrontare i diversi gruppi etnici e di genere, evidenziando eventuali differenze nella distribuzione delle malattie croniche.

Per approfondire questa analisi, sono stati estrapolati tutti i valori univoci presenti in *StratificationCategory* e nei relativi *Stratification*.

Inoltre, è stato aggiunto un conteggio delle occorrenze per ogni combinazione di *StratificationCategory* e *Stratification*. Questo passaggio si è rivelato fondamentale per visualizzare la distribuzione delle occorrenze attraverso semplici plot, consentendo di verificare se la raccolta dei dati all'interno di questo dataset sia bilanciata o presenti eventuali bias. Identificare possibili squilibri nella distribuzione dei dati per razza, etnia o genere è cruciale per garantire un'analisi accurata e rappresentativa.



Figura 3

Il barplot mostra una distribuzione equilibrata dei dati tra le categorie di stratificazione Gender e Overall, senza evidenti squilibri o sovra-rappresentazioni. Per quanto riguarda la categoria Race invece ci sono dei sbilanciamenti, per alcuni topic, nel numero di record presenti per le diverse etnie.

2.6 Distribuzioni divise per DataValueType⁺

Nell'ambito di un'analisi esplorativa completa, si è ritenuto fondamentale procedere con la visualizzazione delle distribuzioni di frequenza dei dati in relazione alle diverse *question* e ai corrispondenti *datavaluetype* esaminati nel paragrafo 2.4. Questa fase si è rivelata cruciale per la selezione dei due *topic* su cui si concentrerà il resto dello studio. In particolare, sono stati individuati i topic “*Diabetes*” e “*Cardiovascular Disease*”, caratterizzati da distribuzioni apparentemente gaussiane e da un volume di dati significativo, elementi essenziali per garantire un'analisi statistica solida e rappresentativa.

Al fine di migliorare la comprensione delle dinamiche distribuzionali e supportare l'eventuale utilizzo dei dati nelle successive *research question*, per ogni fenomeno analizzato sono state inoltre calcolate e sovrapposte alle distribuzioni le principali misure di centralità e dispersione (media, mediana, moda, varianza e deviazione standard). La loro rappresentazione diretta all'interno dei grafici ha permesso una valutazione immediata della forma, della simmetria e della variabilità delle distribuzioni, facilitando l'individuazione dei casi più idonei a ulteriori approfondimenti statistici.

Di seguito un esempio per la *question* “Mortalità con chetoacidosi diabetica”, espressa come *Crude Prevalence (DataValueType)* per il *topic* “Diabetes”:




Figura 4

2.7 Verifica delle distribuzioni⁺

Successivamente alla fase di analisi esplorativa e alla visualizzazione delle distribuzioni empiriche, si è proceduto con una verifica formale della loro aderenza a specifiche distribuzioni teoriche. L'obiettivo di questa analisi è stato quello di comprendere se i dati osservati potessero essere ragionevolmente descritti da modelli probabilistici noti, così da disporre di

una base statistica più solida per le analisi successive e per la corretta selezione dei test inferenziali da applicare.

In particolare, per ciascuna combinazione di *question*, *DataValueType* e *topic* selezionata, è stata confrontata la distribuzione empirica dei dati con una o più distribuzioni teoriche candidate, con particolare attenzione alla distribuzione normale, data la sua rilevanza nelle applicazioni statistiche e la forma apparentemente gaussiana osservata in diversi casi durante l'analisi preliminare.

La verifica dell'adattamento è stata condotta mediante il test del chi-quadrato (χ^2), che consente di valutare l'ipotesi nulla secondo cui i dati osservati provengano da una specifica distribuzione teorica. A tal fine, i valori continui sono stati preliminarmente discretizzati in classi, assicurando un numero sufficiente di osservazioni attese per ciascun intervallo, condizione necessaria per la validità del test. Le frequenze osservate sono state quindi confrontate con le frequenze attese calcolate sulla base della distribuzione teorica considerata, i cui parametri sono stati stimati a partire dai dati stessi.

Il risultato del test del chi-quadrato ha permesso di ottenere, per ciascuna distribuzione analizzata, un indicatore quantitativo del grado di scostamento tra le frequenze osservate e quelle attese secondo il modello teorico considerato, consentendo di valutare in modo oggettivo la tipologia di distribuzione maggiormente compatibile con i dati in esame. Questa fase di verifica ha fornito una panoramica più chiara e rigorosa della natura statistica dei dati.

2.8 Verifica delle ipotesi⁺

Al fine di completare il quadro analitico e approfondire la comprensione dei dati analizzati, all'analisi descrittiva e distribuzionale è stata affiancata una fase di verifica formale di alcune ipotesi statistiche. Tale fase non è stata condotta con finalità strettamente predittive, bensì come strumento di analisi esplorativa avanzata, volto a valutare la capacità informativa del dataset e l'applicabilità di tecniche inferenziali coerenti con la struttura dei dati disponibili.

In particolare, sono state formulate ipotesi statistiche riferite a specifici *topic* e indicatori, utilizzando valori soglia derivanti da obiettivi ufficiali di sanità pubblica definiti in periodi precedenti a quello osservato. Questo approccio ha permesso di confrontare le stime empiriche ottenute dal dataset con target numerici reali, consentendo una valutazione quantitativa del grado di scostamento tra i valori osservati e gli obiettivi prefissati.

Per ciascun caso di studio è stato costruito un test di verifica delle ipotesi monolaterale, e il relativo *p-value* è stato utilizzato come misura del grado di compatibilità tra i dati osservati e l'ipotesi nulla. In questo modo, è stato possibile stabilire se le differenze riscontrate rispetto ai valori di riferimento potessero essere attribuite a fluttuazioni casuali oppure se indicassero una deviazione statisticamente significativa dai target di policy considerati.

2.9 Moda sui Dati Qualitativi

Per completare l'analisi esplorativa e garantire un'esaminazione approfondita dei dati contenuti nel dataset, si è proceduto all'elaborazione dei dati qualitativi (testuali) relativi a tre specifici *datavaluetype* che esprimono informazioni categoriali di rilievo.

Il primo, *"Local authority to regulate alcohol outlet density"*, rappresenta le politiche adottate dai diversi stati per la regolamentazione della densità dei punti vendita di alcolici. I valori numerici associati indicano le diverse categorie di regolamentazione applicate.

Il secondo, *"Commercial host (dram shop) liability status for alcohol service"*, fornisce informazioni sullo stato della responsabilità legale degli esercizi commerciali (dram shop) nella vendita di alcolici. I *datavalue* associati a questa variabile sono espressi tramite categorie numerate, accompagnate da descrizioni specifiche, come ad esempio *"State had commercial host liability with no major limitations"*, che indica l'esistenza di una responsabilità legale senza restrizioni significative.

Infine, il *datavaluetype* *"Yes/No"* esprime una risposta binaria rispetto a diverse questioni, con un valore positivo o negativo in base al contesto analizzato. Ad esempio, nel topic *"Tobacco"*, esso indica la presenza o meno di un'accisa sui prodotti del tabacco, mentre nel topic *"Nutrition, Physical Activity, and Weight Status"*, può rappresentare l'esistenza di normative sul tempo di esposizione agli schermi nei contesti educativi per la prima infanzia.

Su questi tre *datavaluetype* è stata calcolata la moda, al fine di evidenziare i valori qualitativi predominanti all'interno delle diverse question in cui tali variabili sono espresse. Ne è risultata la seguente tabella (la question per comodità è espressa con il relativo ID):

"topic"	"questionid"	"datavaluetypeid"	"mode _{value} "
"Alcohol"	"ALC10 ₀ "	"LclCntrlAlc"	"Category 3 - State had exclusive state alcohol retail licensing but with local zoning authority"
"Alcohol"	"ALC9 ₀ "	"CommHstLiab"	"Category 2 - State had commercial host liability with major limitations"
"Tobacco"	"TOB4 ₀ "	"YesNo"	"Yes"
"Tobacco"	"TOB5 ₀ "	"YesNo"	"Yes"
"Tobacco"	"TOB7 ₀ "	"YesNo"	"No"

Tabella 3

3 Obiettivi del Progetto

Nel presente lavoro sono state individuate tre principali *research questions*, finalizzate a guidare l'analisi dei dati e la valutazione dei risultati. In particolare, si intende rispondere ai seguenti quesiti:

1. In che misura i dati generati da modelli LLM sono in grado di preservare le proprietà statistiche dei dati reali?
2. I dati contenuti nel dataset possono essere considerati adeguati per lo sviluppo di modelli predittivi sui fenomeni analizzati?
3. È possibile identificare pattern di raggruppamento significativi tra le diverse categorie etniche sulla base dei fenomeni osservati nel dataset? In particolare, esistono evidenze di correlazione tra appartenenza etnica e l'insieme dei fenomeni analizzati?

4 Research Question: 1

La prima research question a cui si intende rispondere è la seguente: *“I dati generati dai LLM sono in grado di mantenere le stesse proprietà statistiche dei dati reali?”*

Per affrontare tale quesito è stata condotta una fase preliminare di *prompt engineering*, con l'obiettivo di massimizzare l'efficienza del modello LLM ed ottenere un dataset sintetico in grado di riempire i valori nulli del dataset originale. L'idea di partenza consisteva nell'inserire valori pseudo-reali, coerenti con le proprietà statistiche dell'insieme di riferimento, evitando soluzioni banali come la sostituzione con medie o mediane.

È importante sottolineare che il prompt utilizzato è rimasto invariato per entrambi gli approcci; la differenza risiede esclusivamente nel modello LLM adottato. In particolare, nel primo approccio è stato impiegato GPT-4 con capacità di ragionamento esteso, mentre nel secondo approccio è stato utilizzato GPT-5, così da valutare come la diversa architettura potesse incidere sui risultati.

4.1 Prompt

Il prompt utilizzato per i due approcci è il seguente:

Hai a disposizione un dataset CSV contenente informazioni sulla salute pubblica negli Stati Uniti, con focus su Diabete. Ogni record è caratterizzato da queste colonne chiave:

- **yearstart**: anno di acquisizione del dato
- **locationabbr**: abbreviazione dello stato USA (escludere i record con valore "US")
- **datavaluetype**: tipo di valore (es. "Crude Prevalence", "Crude Rate", "Age-adjusted Rate", ecc.)
- **stratificationcategory1**: categoria di stratificazione del dato (es. "Overall", "Gender", "Race/Ethnicity")
- **datavalue**: valore numerico da analizzare (può essere null)

Istruzioni:

1. Escludere tutti i record con `locationabbr == "US"`.
2. Calcolare statistiche descrittive (*count*, *mean*, *std*, *min*, *25%*, *50%*, *75%*, *max*) della colonna `datavalue` per tutte le combinazioni dei seguenti attributi:
 - `yearstart`
 - `locationabbr`
 - `datavaluetype`
 - `stratificationcategory1`
3. Per ogni record con `datavalue` nullo, sostituirlo con un valore sintetico coerente con le statistiche della sua specifica combinazione di attributi.
4. Generare un nuovo dataset identico all'originale, ma con i valori nulli riempiti, da salvare in formato CSV.

Output richiesto:

- Un dataset completo senza valori nulli nella colonna `datavalue`.
- Salvataggio del dataset risultante in formato `.csv`.

4.2 Primo approccio (GPT-4)

L'analisi dei risultati ottenuti da questo primo approccio ha evidenziato un limite significativo. Il modello, infatti, ha generato i valori sintetici sulla base di statistiche aggregate (media, mediana, ecc.), mantenendo invariate le proprietà statistiche globali, ma senza introdurre dati plausibili dal punto di vista semantico. In altre parole, i valori imputati risultano privi di significato reale e svolgono unicamente la funzione di preservare le distribuzioni originali.

Tale comportamento non risponde pienamente agli obiettivi prefissati, in quanto lo scopo era ottenere dati sintetici non solo statisticamente coerenti, ma anche plausibili e interpretabili in relazione al fenomeno osservato.




Figura 5: Visualizzazione delle statistiche del dataset sintetico generato col primo approccio (GPT-4).

4.3 Secondo approccio (GPT-5)

In questo secondo approccio viene mantenuto lo stesso prompt del primo; la differenza risiede esclusivamente nel modello utilizzato, passando a **GPT-5**. L’obiettivo rimane quello di imputare i valori mancanti della variabile **datavalue** preservando il più possibile le proprietà statistiche osservate nei dati reali e garantendo, al contempo, una plausibilità semantica dei valori generati.

Idea di fondo e ragionamento del modello. Il modello adotta una tecnica di imputazione *hot-deck condizionata per gruppo*: quando incontra un record con **datavalue** mancante, anziché produrre una media o una mediana, campiona con rimpiazzo uno tra i valori realmente osservati all’interno dello stesso contesto statistico. Il contesto (o “gruppo”) è definito dalla quadrupla di attributi:

(**yearstart**, **locationabbr**, **datavaluetype**, **stratificationcategory1**).

Questo ragionamento riproduce la distribuzione empirica condizionata del fenomeno nel gruppo di riferimento: i valori imputati risultano quindi plausibili perché “somigliano” a valori realmente osservati in condizioni identiche.

Strategia di backoff multi-livello. Quando in un gruppo mancano completamente valori osservati (o sono troppo pochi), il modello applica un meccanismo di backoff su pool progressivamente più ampi, così da conservare quante più informazioni contestuali possibile e minimizzare la distorsione statistica:

1. **G0 (gruppo esatto):** campionamento dai *datavalue* osservati nella stessa quadrupla (**yearstart**, **locationabbr**, **datavaluetype**, **stratificationcategory1**).
2. **G1 (stesso anno e tipo, tutte le regioni):** se G0 non è disponibile, campionamento dal pool (**yearstart**, **datavaluetype**, **stratificationcategory1**) aggregando stati diversi.
3. **G2 (stesso tipo su tutti gli anni e regioni):** se G1 non è disponibile, campionamento dal pool (**datavaluetype**, **stratificationcategory1**).
4. **G3 (globale):** in assenza di alternative, campionamento dall’intero insieme di valori osservati.

Questa gerarchia preserva progressivamente le componenti più informative (anno, tipologia metrica, stratificazione) e riduce il rischio di introdurre bias sistematici quando le celle sono scarsamente popolate.

Perché l’hot-deck preserva le proprietà statistiche. Campionare con rimpiazzo dalla distribuzione empirica osservata in un gruppo implica che, in aspettativa, le statistiche descrittive (media, quantili, varianza) del gruppo restino invariate. In altri termini, l’imputazione non “inventa” una nuova distribuzione, ma ne replica la forma osservata: ciò consente di alterare minimamente il profilo statistico complessivo, soprattutto quando la percentuale di mancanti è contenuta. Inoltre, la natura condizionata per gruppo aiuta a mantenere

coerenza rispetto alle dimensioni `yearstart`, `datavaluetype` e `stratificationcategory1`, elementi cruciali per le analisi successive.

Implementazione concettuale. In termini operativi, il modello procede come segue: (1) esclude i record con `locationabbr == "US"`; (2) calcola le statistiche descrittive dei `datavalue` osservati per ciascun gruppo; (3) individua le righe con valori mancanti e, per ciascuna, seleziona il pool più specifico disponibile tra G0–G3; (4) campiona con rimpiazzo un valore dal pool selezionato; (5) produce il dataset imputato completo. Tale pipeline massimizza la plausibilità dei valori imputati e limita l’alterazione delle metriche di sintesi a livello di gruppo e globale.

Osservazioni. Rispetto ad approcci basati su medie/mediane, l’*hot-deck* preserva la variabilità interna ai gruppi e riduce l’appiattimento delle distribuzioni, evitando di sottostimare la varianza. Al contempo, il backoff su pool più ampi impedisce che gruppi poco densi generino imputazioni instabili, garantendo una copertura robusta dell’intero dataset.




Figura 6: Visualizzazione delle statistiche del dataset sintetico generato col secondo approccio (GPT-5) tramite imputazione *hot-deck* condizionata e backoff multi-livello.

5 Research Question: 2

La seconda research question oggetto di indagine è la seguente: “*I dati contenuti nel dataset possono essere considerati adeguati per lo sviluppo di modelli predittivi sui fenomeni analizzati?*”

5.1 Matrici di Correlazione

Per rispondere a tale quesito è stata condotta un’analisi di correlazione focalizzata sui fenomeni *Cardiovascular Disease* (CVD) e *Diabetes* (DIA). In particolare, per ciascun **datavaluetype** presente nel dataset sono state costruite matrici di correlazione di Pearson confrontando tutti gli indicatori disponibili relativi ai due fenomeni. È importante sottolineare che, dato un determinato **datavaluetype**, nella matrice di correlazione sono state incluse tutte le **question** (indipendentemente dal **topic**) che presentavano valori in **datavalue** con quello specifico **datavaluetype**. Per tale motivo, le matrici ottenute risultano di dimensioni variabili, più o meno ampie a seconda del numero di indicatori disponibili. L’obiettivo di questa fase era duplice: da un lato, valutare la presenza di relazioni statistiche tra variabili differenti; dall’altro, verificare se tali relazioni potessero supportare l’identificazione di variabili dipendenti e indipendenti da utilizzare in un eventuale modello di regressione. A titolo esemplificativo, in Figura 7 viene riportata una delle matrici di correlazione ottenute.




Figura 7: Matrice di correlazione tra differenti question dei topic DIA e CVD sul datavaluetype = “Crude Rate”.

I risultati evidenziano come i valori di correlazione elevata compaiano unicamente in due circostanze: (1) quando due variabili descrivono sostanzialmente lo stesso fenomeno con codici differenti; (2) quando una variabile rappresenta un sottoinsieme diretto dell'altra.

Codice	Descrizione
CVD1.1	Mortality from total cardiovascular disease
CVD1.2	Mortality from diseases of the heart

Tabella 4: Esempio del caso 2.

In tali casi, la correlazione risulta inevitabile e riflette una ridondanza semantica piuttosto che una relazione predittiva di interesse. Al contrario, quando si considerano fenomeni distinti, le correlazioni risultano deboli o del tutto assenti, non emergendo pattern relazionali significativi. Sono state ovviamente esplorate anche altre possibili associazioni tra topic differenti, ad esempio quelle più intuitive come *Tobacco* $\rightarrow$ *Cardiovascular Disease* oppure *Alcohol* $\rightarrow$ *Cardiovascular Disease/Diabetes*. Tuttavia, anche in questi casi non sono emerse correlazioni nette utili all'impostazione di task di regressione. Una possibile spiegazione risiede nell'elevata eterogeneità del dataset: la diversificazione della tipologia di dati disponibili comporta che, per ogni combinazione di feature, siano spesso presenti solo pochi dati in termini quantitativi, rendendo difficile individuare pattern robusti e generalizzabili.

Questo risultato porta a una conclusione rilevante: il dataset, nella sua configurazione attuale e con riferimento agli indicatori analizzati, non offre un livello di informazione sufficiente per lo sviluppo di modelli predittivi robusti. L'assenza di correlazioni consistenti tra fenomeni differenti implica infatti la difficoltà di individuare coppie di variabili con ruoli ben distinti di dipendente e indipendente, condizione necessaria per l'impostazione di un modello di regressione affidabile. In altri termini, i dati non catturano interdipendenze strutturali utili alla previsione, ma riflettono principalmente sovrapposizioni concettuali tra variabili già molto simili.

5.2 Limitazioni e direzioni di miglioramento

Alla luce di tali considerazioni, l'analisi è stata volutamente circoscritta alla sola verifica delle correlazioni, senza procedere allo sviluppo di modelli di regressione che, nelle condizioni attuali, avrebbero prodotto risultati scarsamente significativi e non generalizzabili.

Per rendere il dataset davvero utile ai fini predittivi, sarebbe necessario integrarlo con nuove variabili esterne, capaci di descrivere meglio i fattori che influenzano in modo diretto i fenomeni analizzati. Alcuni esempi possono essere:

- indicatori socio-economici (reddito medio, livello di istruzione, condizioni occupazionali);
- indicatori comportamentali (livelli di attività fisica, etc.);
- indicatori sanitari (accesso ai servizi sanitari, spesa sanitaria pro capite).

L'integrazione di tali informazioni ampliherebbe la base informativa del dataset, permettendo di individuare relazioni statisticamente robuste e supportando l'applicazione di

modelli di regressione e predizione più affidabili e significativi. In tal modo, sarebbe possibile superare i limiti emersi in questa fase ed evolvere da un'analisi puramente descrittiva e correlazionale verso modelli predittivi con effettiva capacità esplicativa e di supporto alle decisioni in ambito epidemiologico e sanitario.

6 Research Question: 3

La terza research question a cui si intende rispondere è la seguente: “È possibile identificare pattern di raggruppamento significativi tra le diverse categorie etniche sulla base dei fenomeni osservati nel dataset? In particolare, esistono evidenze di correlazione tra appartenenza etnica e l'insieme dei fenomeni analizzati?”

Per investigare tale quesito, sono state adottate due metodologie complementari: un'analisi di clustering non supervisionato e un approccio supervisionato di classificazione. L'obiettivo era duplice: verificare, da un lato, se i dati presentassero una naturale tendenza a raggrupparsi in cluster coerenti con le categorie etniche e, dall'altro, misurare la capacità predittiva di un modello di classificazione basato sui fenomeni contenuti nel dataset.

6.1 Analisi di clustering (K-Means)

In una prima fase è stata condotta un'analisi non supervisionata tramite l'algoritmo **K-Means**. La scelta di fissare il numero di cluster a $k = 7$ deriva dal fatto che nel dataset sono presenti sette categorie etniche distinte: idealmente, se esistesse una forte correlazione tra i fenomeni osservati e l'appartenenza etnica, l'algoritmo avrebbe dovuto produrre cluster separati e quasi esclusivamente composti da individui della stessa etnia. In tal caso, la struttura dei dati avrebbe riflesso una corrispondenza diretta tra etnia e fenomeno.

Per garantire una valutazione più robusta, l'algoritmo è stato applicato in maniera iterativa su tutte le combinazioni possibili delle variabili `topic`, `questionid`, `datavaluetype` e `datavalueunit`. In questo modo è stato possibile osservare se, indipendentemente dal contesto specifico (es. un determinato fenomeno sanitario o una particolare tipologia di metrica), emergessero strutture di raggruppamento riconducibili alle categorie etniche.

I risultati hanno mostrato che i cluster generati non erano ben separati: le osservazioni appartenenti a diverse etnie tendevano a mescolarsi e non si osservavano confini netti. In altre parole, l'algoritmo non ha individuato pattern di separazione chiari tra le etnie. Questo suggerisce che le variabili disponibili nel dataset non contengono informazioni sufficienti a determinare una segmentazione naturale basata sull'etnia, o che la varianza interna a ciascun gruppo è troppo elevata per permettere una distinzione netta.

Dal punto di vista metodologico, occorre sottolineare che **K-Means** si basa sulla minimizzazione della distanza euclidea dai centroidi: ciò implica che i cluster rilevati rispecchiano principalmente strutture sferiche nei dati. In presenza di variabili eterogenee, correlazioni complesse o distribuzioni non lineari, l'algoritmo può risultare limitato. Questo spiega in parte la difficoltà nell'individuare cluster coerenti con le categorie etniche.




Figura 8: Esempio di cluster ottenuti su una specifica combinazione di feature.

6.2 Classificazione supervisionata (Random Forest)

Nella seconda fase è stato adottato un approccio supervisionato, basato sull'addestramento di un classificatore **Random Forest** con 300 alberi decisionali. In questo caso, le variabili presenti nel dataset sono state utilizzate come *feature* di input, mentre l'etnia ha rappresentato la variabile target da predire. L'obiettivo era valutare in che misura le informazioni contenute nei fenomeni osservati potessero essere sfruttate per discriminare tra le diverse categorie etniche.

I risultati hanno evidenziato una **stima di errore OOB pari al 44,98%**, a indicare che il modello commette errori in quasi la metà dei casi già in fase di training. L'**accuratezza sul test set si è attestata al 55,18%**, un valore che, pur essendo superiore al livello di classificazione casuale, rimane modesto e non sufficiente a garantire una predizione affidabile.

Per comprendere meglio questo risultato è utile introdurre il concetto di *livello casuale*. In un problema di classificazione con sette classi equiprobabili, la probabilità di indovinare correttamente un'istanza scegliendo in modo casuale è pari a circa il 14%. Un'accuratezza del 55% rappresenta quindi un miglioramento significativo rispetto a questa baseline, poiché il modello mostra di aver appreso una parte delle relazioni tra variabili e appartenenza etnica. Tuttavia, ciò non implica necessariamente una buona capacità predittiva: superare la soglia casuale è condizione necessaria ma non sufficiente per considerare il modello robusto. In questo caso, il margine di miglioramento rispetto al caso casuale è limitato e segnala che le informazioni disponibili nel dataset, pur contenendo alcuni segnali utili, non sono abbastanza forti per supportare una classificazione precisa.

L'analisi degli errori per gruppo etnico ha inoltre mostrato una notevole eterogeneità. Il modello ha riconosciuto con maggiore precisione il gruppo *White, non-Hispanic*, con un tasso di errore di circa il 16%. Le prestazioni sono risultate peggiori per altri gruppi: *Asian or Pacific Islander* (errore $\sim 47\%$), *Black, non-Hispanic* (errore $\sim 54\%$) e *Hispanic* (errore $\sim 57\%$). Particolarmente critici i risultati per i gruppi minoritari come *American Indian or Alaska Native* (errore $\sim 76\%$) e soprattutto *Multiracial* e *Other*, dove il tasso di errore ha superato il 90%.

Questi risultati indicano che il modello riesce a discriminare meglio i gruppi più rappresentati nel dataset, mentre fatica a riconoscere quelli meno numerosi, spesso confondendoli con altre etnie. Ciò evidenzia sia un problema di sbilanciamento dei dati, sia la difficoltà delle variabili disponibili nel catturare pattern distintivi sufficientemente forti per una classificazione accurata.




Figura 9: Risultati della classificazione con Random Forest (300 alberi). L'immagine mostra: (1) la matrice di confusione normalizzata, che evidenzia la distribuzione delle predizioni tra le diverse etnie; (2) il tasso di errore OOB per ciascun gruppo etnico, con forti differenze tra maggioranze e minoranze; (3) l'importanza delle variabili misurata in termini di *MeanDecreaseAccuracy*; (4) l'importanza delle variabili misurata in termini di *MeanDecreaseGini*. I risultati confermano una migliore predizione per i gruppi più rappresentati, mentre le minoranze risultano spesso mal classificate.

6.3 Valutazione della bontà dei cluster⁺

Al fine di valutare la qualità dei raggruppamenti ottenuti tramite clustering, è stata condotta un'analisi quantitativa della bontà dei cluster basata su metriche interne.

La valutazione è stata effettuata analizzando la *Within-Cluster Sum of Squares* (WCSS) e la *Between-Cluster Sum of Squares* (BCSS), due indicatori fondamentali per misurare rispettivamente la compattezza interna dei cluster e la loro separazione reciproca. Valori contenuti di WCSS indicano cluster internamente omogenei, mentre valori elevati di BCSS suggeriscono una buona distinzione tra i gruppi individuati.

Per determinare il numero ottimale di cluster k , è stato utilizzato l'*elbow method*, che prevede l'osservazione dell'andamento della WCSS al variare del numero di cluster. L'analisi ha evidenziato una marcata riduzione della WCSS fino a $k = 4$, oltre il quale i miglioramenti risultano progressivamente marginali. Tale comportamento ha motivato la scelta di quattro cluster come compromesso ottimale tra complessità del modello e capacità descrittiva dei dati.

A supporto di questa scelta, è stato inoltre calcolato l'indice di Calinski-Harabasz, definito come il rapporto tra BCSS e WCSS. Il valore ottenuto per $k = 4$ indica un equilibrio soddisfacente tra separazione inter-cluster e coesione intra-cluster, confermando la bontà del partizionamento individuato.

L'analisi grafica dei cluster ha mostrato una suddivisione coerente dei dati lungo l'asse dei valori osservati, con centroidi ben distinti e una distribuzione dei punti che riflette differenze strutturali significative tra i gruppi. Inoltre, l'esplorazione della composizione dei cluster rispetto alle variabili di stratificazione, come l'etnia, ha fornito ulteriori elementi interpretativi utili a collegare i risultati del clustering alle *research question* di interesse.

6.4 Discussione dei risultati

L'uso combinato di clustering non supervisionato e classificazione supervisionata ha fornito una visione più completa del problema. Da un lato, **K-Means** ha mostrato l'assenza di una struttura latente che separi chiaramente i dati in base all'etnia; dall'altro, la **Random Forest** ha confermato che, sebbene esistano alcune correlazioni tra variabili e appartenenza etnica, esse non sono abbastanza forti da consentire una classificazione accurata e generalizzabile.

Questi risultati portano a due riflessioni principali. Primo, il dataset analizzato non appare sufficiente per derivare conclusioni robuste sulla correlazione tra etnia e fenomeni osservati: la mancanza di variabili esplicative più dettagliate e la presenza di rumore rendono difficile isolare pattern significativi. Secondo, la presenza di correlazioni parziali suggerisce che ulteriori analisi, integrate con dati più ricchi (ad esempio socio-economici o ambientali), potrebbero evidenziare relazioni più forti. In assenza di tali integrazioni, i risultati restano indicativi ma non conclusivi.